RETO 1 · SAA + PIA + MIA

De la predicción a la acción

Reto **por parejas**. El proyecto debe estar **contextualizado en un negocio** y **responder a una necesidad real** de ese negocio:

1. elegís el problema de una empresa
2. construís un modelo que lo predice
3. le dais una **utilidad**, de forma que la predicción se convierte en una decisión y en una acción.

Es un único proyecto en un único repositorio, pero **cada asignatura lo evalúa por separado**, con su propia rúbrica.

En la defensa, la pareja expone el proyecto en **15 minutos**. Pasados los 15 minutos, **se corta la exposición aunque no se haya terminado**.

Después, cada alumno/a responde individualmente a **3 preguntas sobre el proyecto, una de cada asignatura**.

Requisitos del dataset

- Datos en tabla, con **valores nulos** y **al menos una variable categórica**.
- Problema de **clasificación** o de **regresión**.

Qué evalúa cada asignatura

Asignatura	Qué mira del proyecto	RA evaluados y peso en el reto (suma 100 %)
SAA	Los datos y los modelos: EDA, nulos, cinco modelos, MLP, comparativa y elección	RA1 5 % · RA2 10 % · RA3 45 % · RA5 20 % · RA6 20 %
PIA	El código: estructura, pipeline de sklearn, MLflow, app de Streamlit y README	RA1 10 % · RA2 90 %
MIA	El problema de negocio, las reglas que deciden y el flujo de n8n que actúa	RA1 20 % · RA5 80 %

Cómo funciona el sistema

Streamlit: caso nuevo → modelo (p) → reglas (decisión) → webhook de n8n → acción

p es la probabilidad que da el modelo (clasificación) o el valor que predice (regresión).

Parte de SAA · datos y modelos

- En el README, apartado "Qué hemos construido": un párrafo que presente vuestro sistema y explique por qué es una IA débil, qué tipo de aprendizaje usa (supervisado: clasificación o regresión) y para qué sirve cada herramienta (scikit-learn, XGBoost, MLflow…).

Análisis de los datos

- **Descripción del dataset:** origen, filas, columnas, variable objetivo y **tabla de campos** (nombre, qué significa, tipo y % de nulos). Va en el notebook de EDA y en el README.
- Calidad de los datos: duplicados, valores imposibles y nulos.
- **Al menos 5 gráficos con matplotlib:** diagrama de barras, una variable numérica (histograma y boxplot), relación entre dos variables (dispersión) y correlación (heatmap). Debajo de cada gráfico, **qué veo** y **qué conclusión saco**.
- Nulos: ¿al azar o con patrón? Imputad según eso.
- Variables nuevas, si tienen sentido.

Modelos

- **Cinco modelos**: regresión, KNN, Random Forest, XGBoost, SVM. GridSearchCV con validación cruzada (si es necesario).
- Si las clases están desbalanceadas, aplicad SMOTE y comparad los resultados con y sin SMOTE.
- **MLP**: modelo base y 3 experimentos cambiando hiperparámetros.
- Tabla comparativa sacada de MLflow: una fila por modelo con sus métricas (train y validación) y el tiempo de entrenamiento. Va en el README, con una captura de MLflow. Debajo, qué modelo elegís y por qué.
- Para el 10 del indicador 9: SHAP con el modelo elegido, calculado con validación (no con test). Qué variables pesan más.
- Test una sola vez, con el modelo elegido, en la app de Streamlit.
- Opcional: probad algo que no hayamos visto en clase (un hiperparámetro, un modelo nuevo…) y comparadlo con lo que teníais.

Métricas y errores del modelo: seleccionad las métricas adecuadas para vuestro problema. En clasificación: recall, precisión, F1 y matriz de confusión

(obligatoria). En regresión: MAE, RMSE, R^2 y un gráfico de valores reales frente a predichos. Explicad qué significan para la empresa.

Parte de PIA · código

- Estructura de carpetas ordenada.
- Preprocesado con un pipeline de sklearn (StandardScaler, OneHotEncoder) que usan todos los modelos.
- Funciones documentadas.
- Modelos y experimentos registrados en MLflow.
- App en Streamlit: evalúa con test el modelo elegido y predice un caso nuevo con la decisión de las reglas.
- requirements.txt
- README.

Parte de MIA · utilidad para el negocio

- En el README: el problema de negocio con un dato, el objetivo (qué se predice, para qué y quién lo usa).
- `src/reglas.py`: 6 reglas o más, con prioridad, porqué y una regla de seguridad.
- Flujo de n8n: webhook → una rama por decisión → la acción que elijáis (Google Sheets, PostgreSQL, Google Calendar, correo…).

Estructura básica del repositorio

```
<nombre-del-proyecto>/
├── README.md
├── requirements.txt
├── data/
│   ├── raw/                  datos originales
│   └── processed/            X_train, X_test, y_train, y_test
├── notebooks/
│   ├── 01_eda.ipynb          EDA, nulos y separación
│   ├── 02_modelos_<A>.ipynb
│   └── 03_modelos_<B>.ipynb
├── src/
│   ├── utils.py              funciones del proyecto
│   ├── reglas.py             reglas (MIA)
│   └── n8n.py                envío al webhook (MIA)
├── app/
│   └── streamlit_app.py
├── models/                   mejor_modelo.joblib
├── n8n/                      flujo.json
└── resultados/               capturas de MLflow y de la app
```

El README

El README es la carta de presentación del proyecto. Los apartados marcados con (*) son obligatorios. Tenéis un ejemplo completo en **README_ejemplo_CV.md,** por si os sirve de ayuda:

Apartado	Qué poner
1. Título y una frase (*)	Qué hace el sistema, para quién y con qué resultado.
2. Captura de la app (*)	Una captura de Streamlit, arriba del todo.
3. La necesidad de negocio más desarrollada (*)	Qué problema tiene la empresa, y a qué necesidad responde el sistema.
4. Qué hemos construido (*)	Un esquema (modelo → reglas → n8n → acción) y un párrafo que presente el sistema y explique por qué es una IA débil y qué tipo de aprendizaje usa.
5. Los datos (*)	Descripción del dataset, tabla de campos y lo más importante que descubristeis en el EDA, con uno o dos gráficos.
6. Resultados (*)	Tabla con los modelos y sus métricas sacada de MLflow, modelo elegido y por qué, resultado de test con sus errores (matriz de confusión o gráfico real frente a predicho) y captura de MLflow.

Rúbrica SAA · Sistemas de Aprendizaje Automático

Cada fila adapta al reto los criterios de evaluación (CE) del RA.

	0 puntos	3 puntos	7 puntos	10 puntos
RA1 5 %				
1. Presenta su sistema explicando por qué es una IA débil *CE a, d, f · Peso 5 %*	No lo menciona.	Dice que es IA débil, sin explicar por qué.	Explica con sus palabras por qué su sistema es IA débil.	Además lo compara con una IA fuerte y razona la respuesta.
RA2 10 %				
2. Explica el tipo de aprendizaje de su problema *CE b, c, d, e · Peso 10 %*	No lo indica.	Solo dice si es clasificación o regresión.	Dice que es aprendizaje supervisado y si es clasificación o regresión.	Además razona el tipo de aprendizaje y en qué se diferencia del aprendizaje no supervisado.
RA3 45 %				
3. Describe el dataset y sus campos *CE a, b · Peso 5 %*	No describe el dataset.	Dice de dónde salen los datos, sin describir los campos.	Tabla con todos los campos: nombre, qué significa y tipo.	Además la tabla indica los nulos de cada campo y qué campos quita y por qué.
4. Analiza los datos con gráficos comentados *CE b · Peso 5 %*	No hay gráficos.	Gráficos sin comentar.	3 o 4 gráficos comentados.	Al menos 5 gráficos comentados: barras, histograma, boxplot, dispersión y heatmap.
5. Trata los nulos y crea variables nuevas *CE c · Peso 5 %*	No trata los nulos.	Rellena o quita los nulos sin explicar por qué.	Explica cómo trata los nulos y por qué (si son al azar o siguen un patrón).	Además crea alguna variable nueva útil y explica por qué. Si no se puede crear, explica la razón.

	0 puntos	3 puntos	7 puntos	10 puntos
6. Entrena y valida los cinco modelos *CE d, e, f, g, h · Peso 30 %*	Ningún modelo funciona.	Menos de 5 modelos.	Los 5 modelos.	Además prueba algo no visto en clase (un hiperparámetro, un modelo nuevo…) y demuestra si mejora o no.
RA5 20 %				
7. Experimenta con una red MLP *CE a, b, c, d · Peso 20 %*	No hay MLP.	Modelo base con menos de 3 experimentos.	Modelo base y 3 experimentos, sin explicar por qué realiza cada experimento.	Modelo base y 3 experimentos, explicando por qué realiza cada experimento.
RA6 20 %				
8. Valida los modelos con las métricas adecuadas a su problema *CE a, b · Peso 10 %*	No calcula métricas.	Usa una sola métrica (por ejemplo, accuracy) sin explicar por qué.	Varias métricas adecuadas, en train y validación. Clasificación: recall, precisión, F1 y matriz de confusión. Regresión: MAE, RMSE, R^2 y gráfico real frente a predicho.	Además explica qué significan los errores del modelo para la empresa.
9. Elige el mejor modelo para el negocio *CE a, b · Peso 5 %*	No compara los modelos.	Elige el de mejor métrica, sin ninguna explicación.	Tabla con las métricas y el tiempo de cada modelo. Elige la métrica según el negocio y, si hay empate, el modelo más simple.	Además explica con SHAP, calculado con validación, qué variables pesan más en el modelo elegido.

	0 puntos	3 puntos	7 puntos	10 puntos
10. Responde a una pregunta individual sobre su proyecto *CE a, b · Peso 5 %* **Nota individual**	No responde o la respuesta no tiene que ver con su proyecto.	Responde de forma general, sin referirse a su proyecto.	Responde bien sobre su proyecto.	Además lo enseña en su código o en sus resultados y explica el porqué.

Rúbrica PIA · Programación de Inteligencia Artificial

	0 puntos	3 puntos	7 puntos	10 puntos
RA1 10 %				
1. Documenta el código y el README *CE e, f · Peso 10 %*	Sin README ni comentarios.	README incompleto o funciones sin documentar.	README con los apartados obligatorios y funciones documentadas.	Además añade apartados propios a los obligatorios.
RA2 90 %				
2. Organiza el código en carpetas y funciones *CE d · Peso 10 %*	Todo en un único notebook.	Código repetido en cada notebook.	Sigue la estructura de carpetas y usa funciones comentadas.	Además `requirements.txt` correcto.
3. Programa el preprocesado con un pipeline de sklearn *CE c, d · Peso 20 %*	No hay preprocesado.	Preprocesa a mano, repitiendo el código en cada modelo.	Un pipeline con StandardScaler y OneHotEncoder que usan todos los modelos.	Además el modelo guardado incluye el pipeline y predice un caso nuevo.
4. Registra los experimentos en MLflow *CE b, e · Peso 20 %*	No usa MLflow.	Solo algunos modelos.	Todos los modelos y experimentos, con hiperparámetros y métricas.	Además compara los modelos en MLflow y lo enseña con capturas.
5. Programa una app en Streamlit *CE d, e · Peso 25 %*	No hay app o no carga el modelo.	Hace solo una de las dos cosas: evalúa con test o predice un caso nuevo.	Hace las dos: muestra las métricas de test con la matriz de confusión (o el gráfico real frente a predicho) y predice un caso nuevo con la decisión de las reglas.	Además muestra la p del caso nuevo (la probabilidad o el valor predicho) junto a la decisión.
6. Responde a una pregunta individual sobre su código *CE c, d · Peso 15 %* **Nota individual**	No responde o la respuesta no tiene que ver con su proyecto.	Responde de forma general, sin referirse a su proyecto.	Responde bien sobre su proyecto.	Además lo enseña en su código o en sus resultados y explica el porqué.

Rúbrica MIA · Modelos de Inteligencia Artificial

	0 puntos	3 puntos	7 puntos	10 puntos
RA1 **20 %**				
1. Contextualiza el problema de negocio con un objetivo claro *CE b, d · Peso 20 %*	No hay contextualización.	Describe el problema, sin objetivo ni datos.	Problema con un dato y objetivo claro: qué se predice, para qué y quién lo usa.	Además indica qué mejora supondría para la empresa.
RA5 **80 %**				
2. Crea reglas que convierten la predicción en una decisión *CE a, b, d · Peso 30 %*	No hay reglas.	Menos de 6 reglas, o sin decisión.	Menos de 6 reglas con prioridad, porqué y una regla de seguridad.	6 reglas o más con prioridad, decisión y una regla de seguridad.
3. Conecta la decisión con un flujo de n8n *CE c, e · Peso 35 %*	No hay flujo.	El flujo no recibe la decisión o hace siempre lo mismo.	Recibe la decisión por webhook y hace una acción distinta según la decisión.	Recibe la decisión por webhook y hace una acción distinta a las vistas en clase según la decisión.
4. Responde a una pregunta individual sobre su proyecto *CE a, c · Peso 15 %* **Nota individual**	No responde o la respuesta no tiene que ver con su proyecto.	Responde de forma general, sin referirse a su proyecto.	Responde bien sobre su proyecto.	Además lo enseña en su código o en sus resultados y explica el porqué.